Shell Session、AI Session 与模型服务：设计总览

把逻辑归属、物理进程和线程调度分开描述；共享进程不等于共享会话，回显不等于执行。

已确认的五条约束

01 主窗口保持普通 Shell；所有 AI 解释、建议说明和验证状态只在侧栏。

02 每页默认绑定独立 Shell / AI Session，页面之间不交换私有上下文。

03 支持多个页面共享 AI 宿主进程，但不默认合并逻辑对话。

04 Scheduler 与 ModelService 从属于 AISession，不能与 Session 平级。

05 纯命令文本可回显到空闲提示符；只有用户 Enter 才真正提交执行。

五个名称，五种职责

对象	负责什么	不是什么
ShellSession	终端状态、命令运行、输入缓冲区与最终回显校验	不是模型，也不是 AI 对话历史
AISession	本页上下文、权限、协议端点与内部能力生命周期	不等于一个 OS 进程
Scheduler	只编排所属会话的检索、模型调用、校验与取消	不是跨 Session 的全局业务调度器
ModelService	所属会话的模型配置、请求、流式响应与超时	不等于独占一份模型权重
AIWorker	承载、注册和路由一个或多个 AISession	不是共享聊天历史或授权容器

阅读顺序：图 01 看归属；图 02-03 看进程；图 04 看线程；图 05-07 看协议、隔离与恢复。

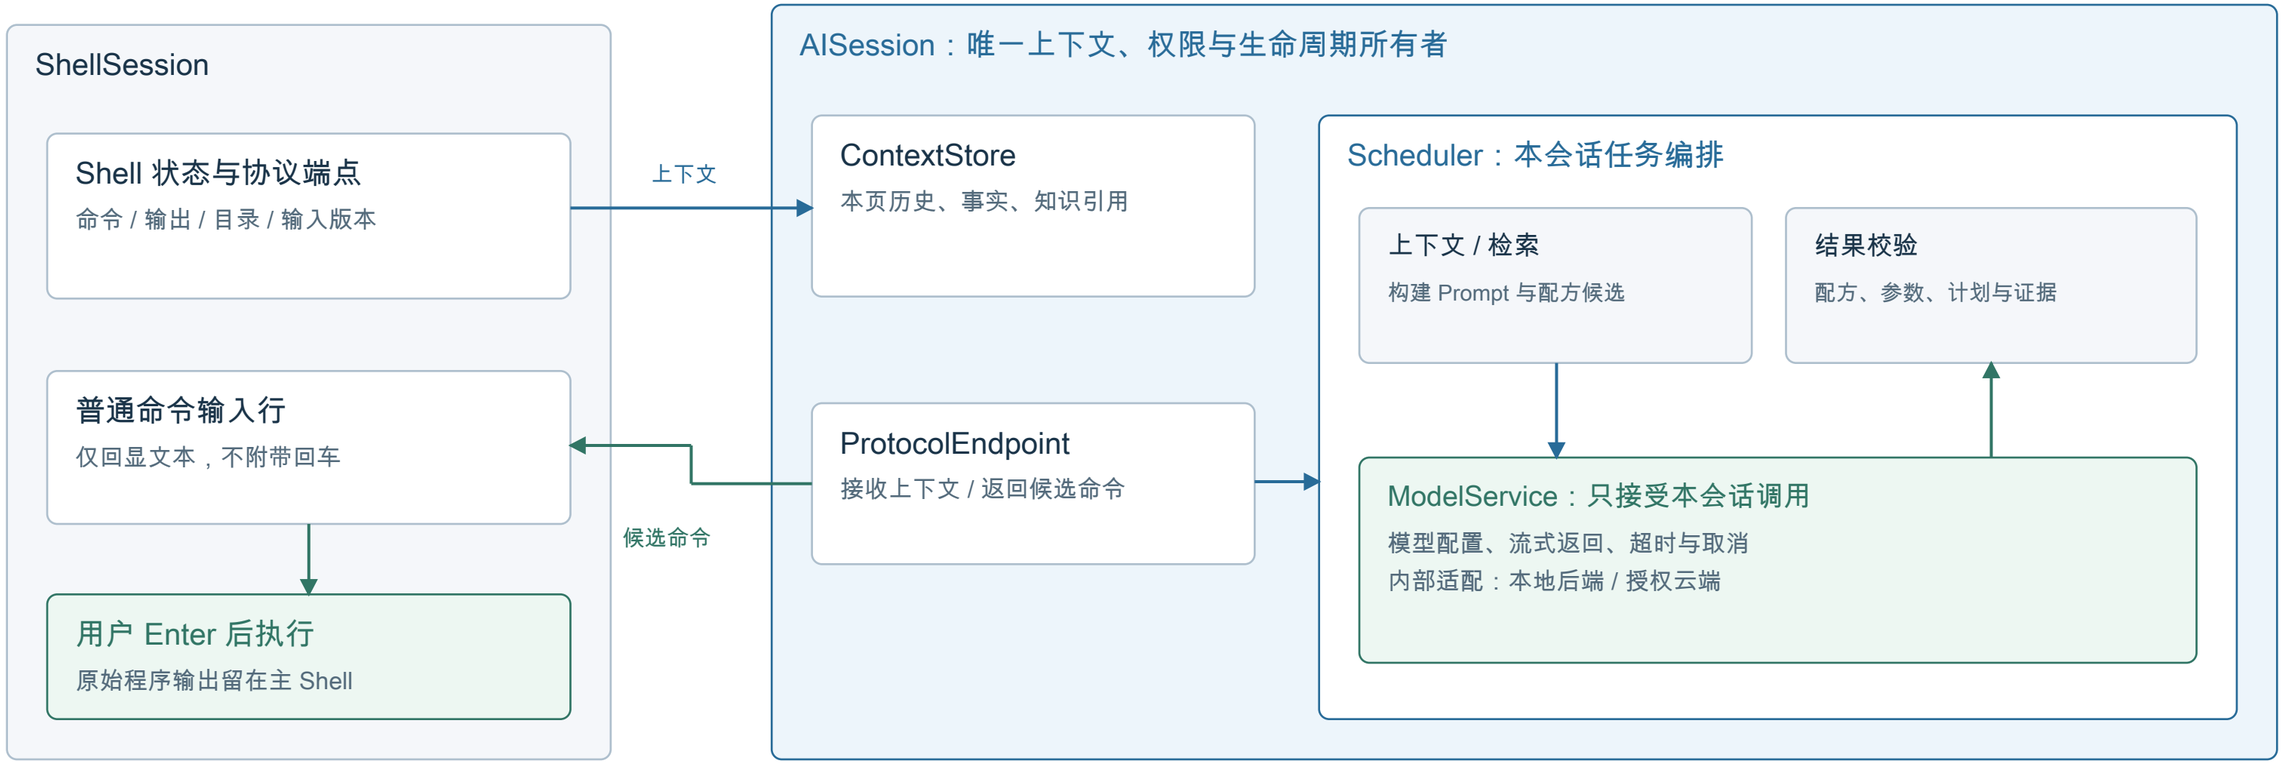
状态说明：上述产品边界已确认；具体进程部署、线程数、IPC 实现、模型后端和系统沙箱能力仍待验证。

01 / 逻辑归属与调用方向

AISession 是上下文和生命周期边界，内部 Scheduler 组织任务，ModelService 只提供推理能力。

图 01　逻辑归属：模型服务在 AISession 内部

嵌套框表示归属，箭头表示消息或调用；不表示一个框就对应一个进程或线程。



关键边界：ModelService 不直接访问 PTY；Scheduler 不跨会话编排；命令回显仍由 Shell 侧校验。

01　对外协议只连接 ShellSession 与 AISession；调度器和模型服务不直接写终端。

02　模型提出候选配方与参数，程序完成校验和命令生成；Shell 侧仍进行最终输入状态检查。

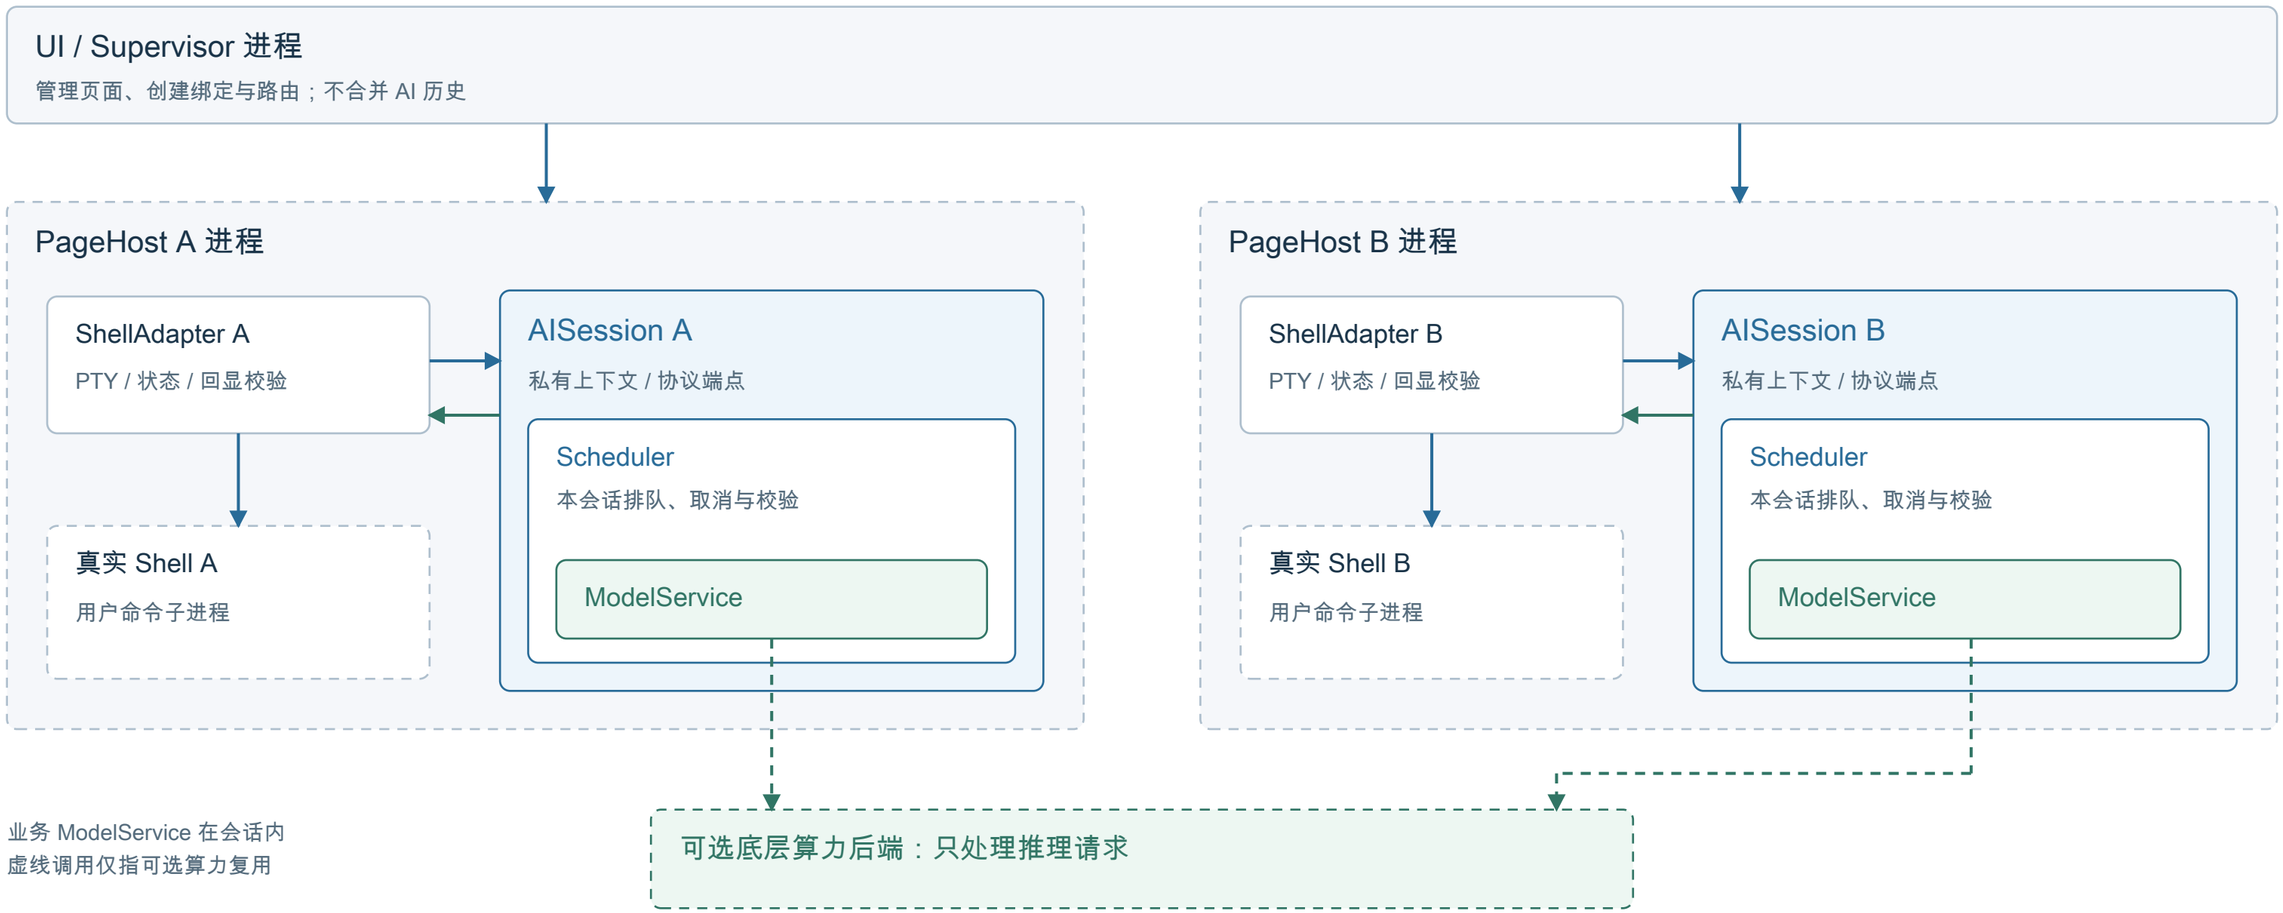
03　此图描述所有权，不规定进程或线程数量。关闭会话时，其队列、模型请求和私有缓存随之清理。

02 / 进程部署模式 A：按页承载

保留早期每页 PageHost 的方案：同页 Shell 适配与 AI 编排同属一个宿主进程。

图 02 进程模式 A：每页承载自己的 AI 执行单元

虚线外框表示 OS 进程边界；真实 Shell 是子进程，AISession 是宿主中的逻辑对象。



01 真实 Shell 是 PageHost 的子进程；AISession 内仍嵌套 Scheduler 与 ModelService。

02 本页模型请求失败可以局部处理；若 PageHost 整体崩溃，本页终端控制可能一同受影响。

03 不同页面宿主独立；是否增加更强 AI 故障隔离或系统沙箱，需要目标设备验证。

03 / 进程部署模式 B：共享 AIWorker

多个 PageHost 通过专属绑定连接共享 AI 进程，各 AISession 内的状态与内部服务保持独立。

图 03 进程模式 B：多个页面共享 AIWorker

共享的是进程，不默认共享对话；每个 AISession 内仍有自己的 Scheduler 与 ModelService。



ModelService 各自选择本地或云端后端；共享 AIWorker 内不设置与 AISession 平级的业务调度器。

01 可信路由表绑定 page_id、shell_session_id、ai_session_id、worker_id 与 binding_epoch。

02 worker_id 只是部署地址；不能作为对话历史、上下文、授权或 KV cache 的唯一索引。

03 共享 AIWorker 故障会影响多个 AI 会话，但不应连带结束外部 PageHost 或真实 Shell。

04 / 线程关系与非阻塞边界

Session 是逻辑对象，线程只是执行资源；推荐单一状态所有者加有界消息队列。

图 04 线程与异步任务：状态由单一执行单元拥有

这是推荐的执行模型，不是固定线程数量；同一线程可承载多个独立 Session actor。



线程不是安全边界：同进程对象靠逻辑隔离；进程级故障按部署模式影响本页或多个 AI 会话。

不允许 AI 持有终端写入句柄；会话调度器不与其他会话共享任务队列或取消状态。

01 Shell I/O 负责真实输入状态和 PTY；AI 侧通过异步请求处理耗时检索和推理。

02 每个 AISession 的 Scheduler 只管理自己的任务；宿主仅限制资源占用，不接管会话业务。

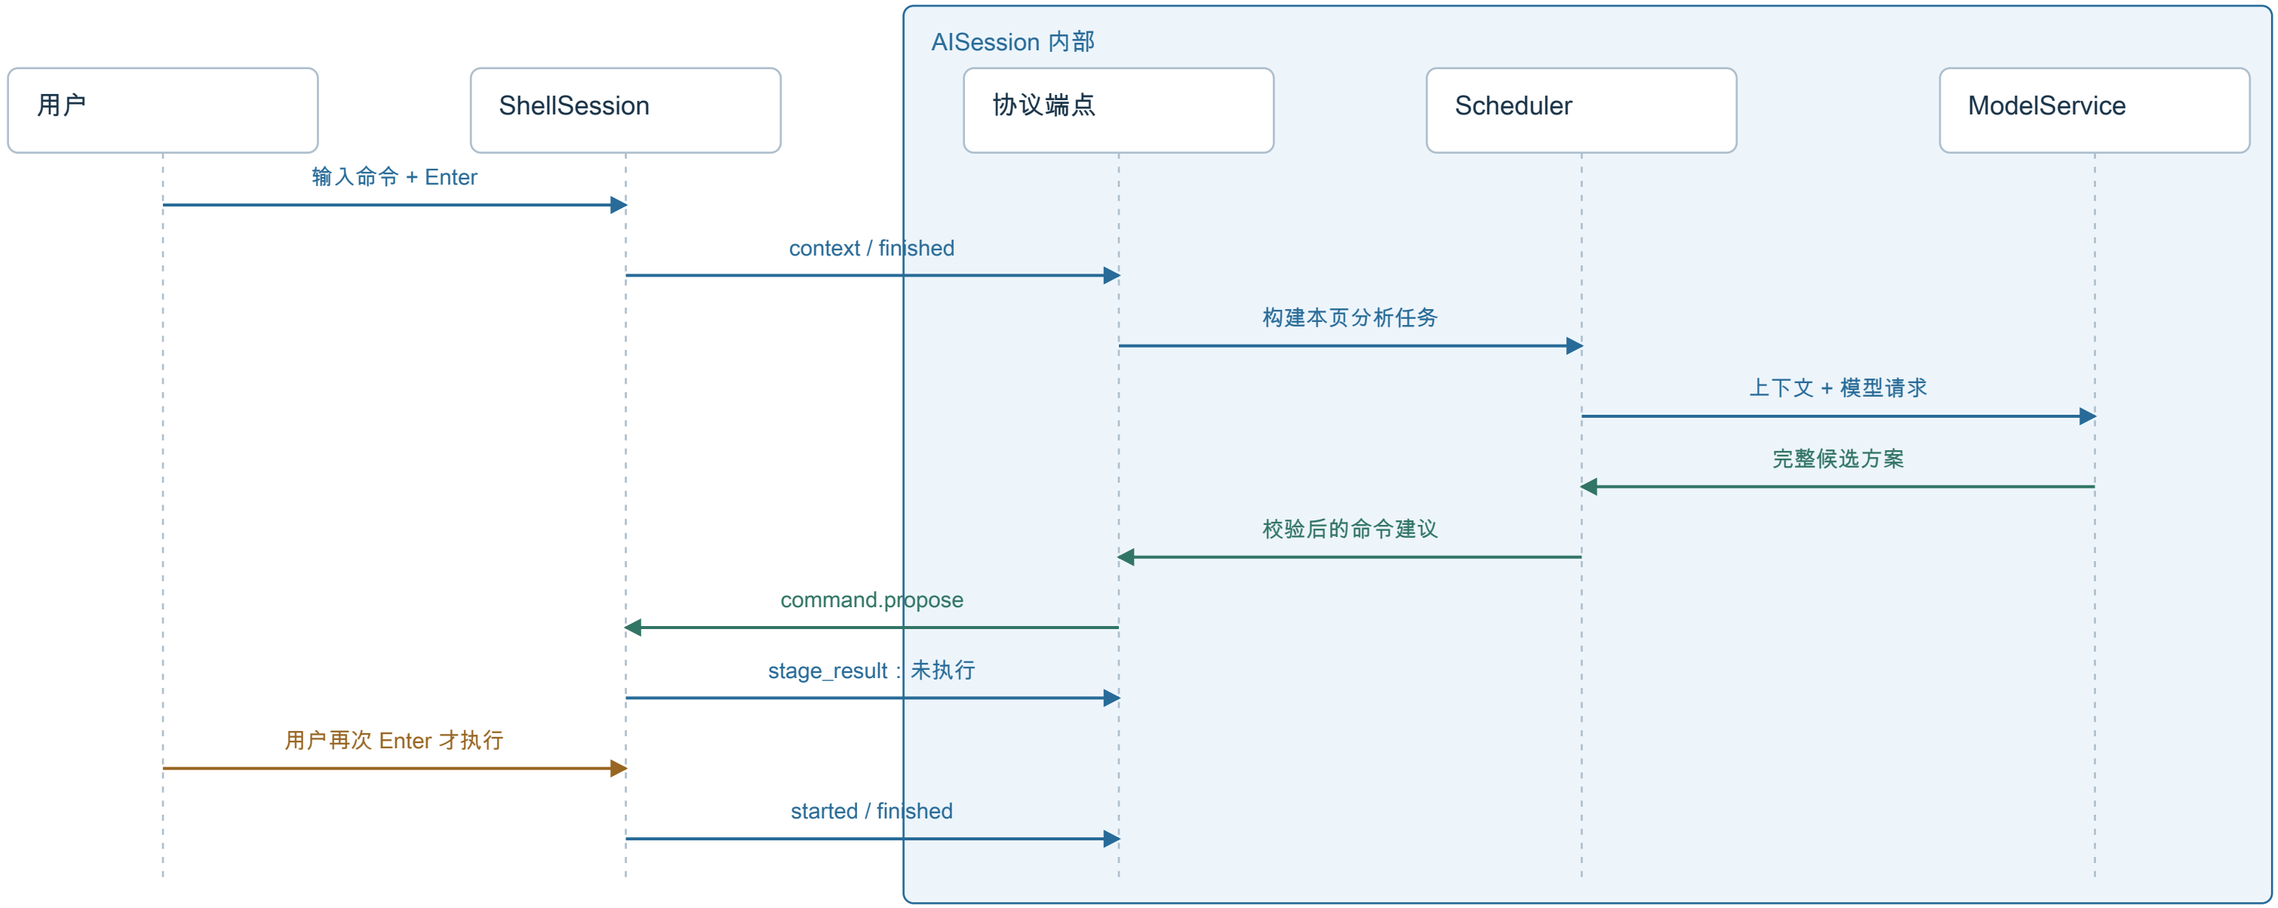
03 检查输入版本与写入必须在同一串行控制点完成；不能先检查、稍后无条件覆盖用户草稿。

05 / 上下文到命令回显的端到端协议

上下文、模型响应、回显回执和执行事件属于不同阶段；协议中不提供 AI 可调用的 shell.execute。

图 05 完整时序：回显不等于执行

AI 相关三个参与者均在同一 AISession 的逻辑范围内；只有用户 Enter 能提交 Shell 命令。



01 AI 解释可流式显示在右侧；完整响应到齐并校验后，才允许生成 command.propose。

02 stage_result=staged 仅表示文本已进入提示符，不代表命令执行或用户已经批准全部副作用。

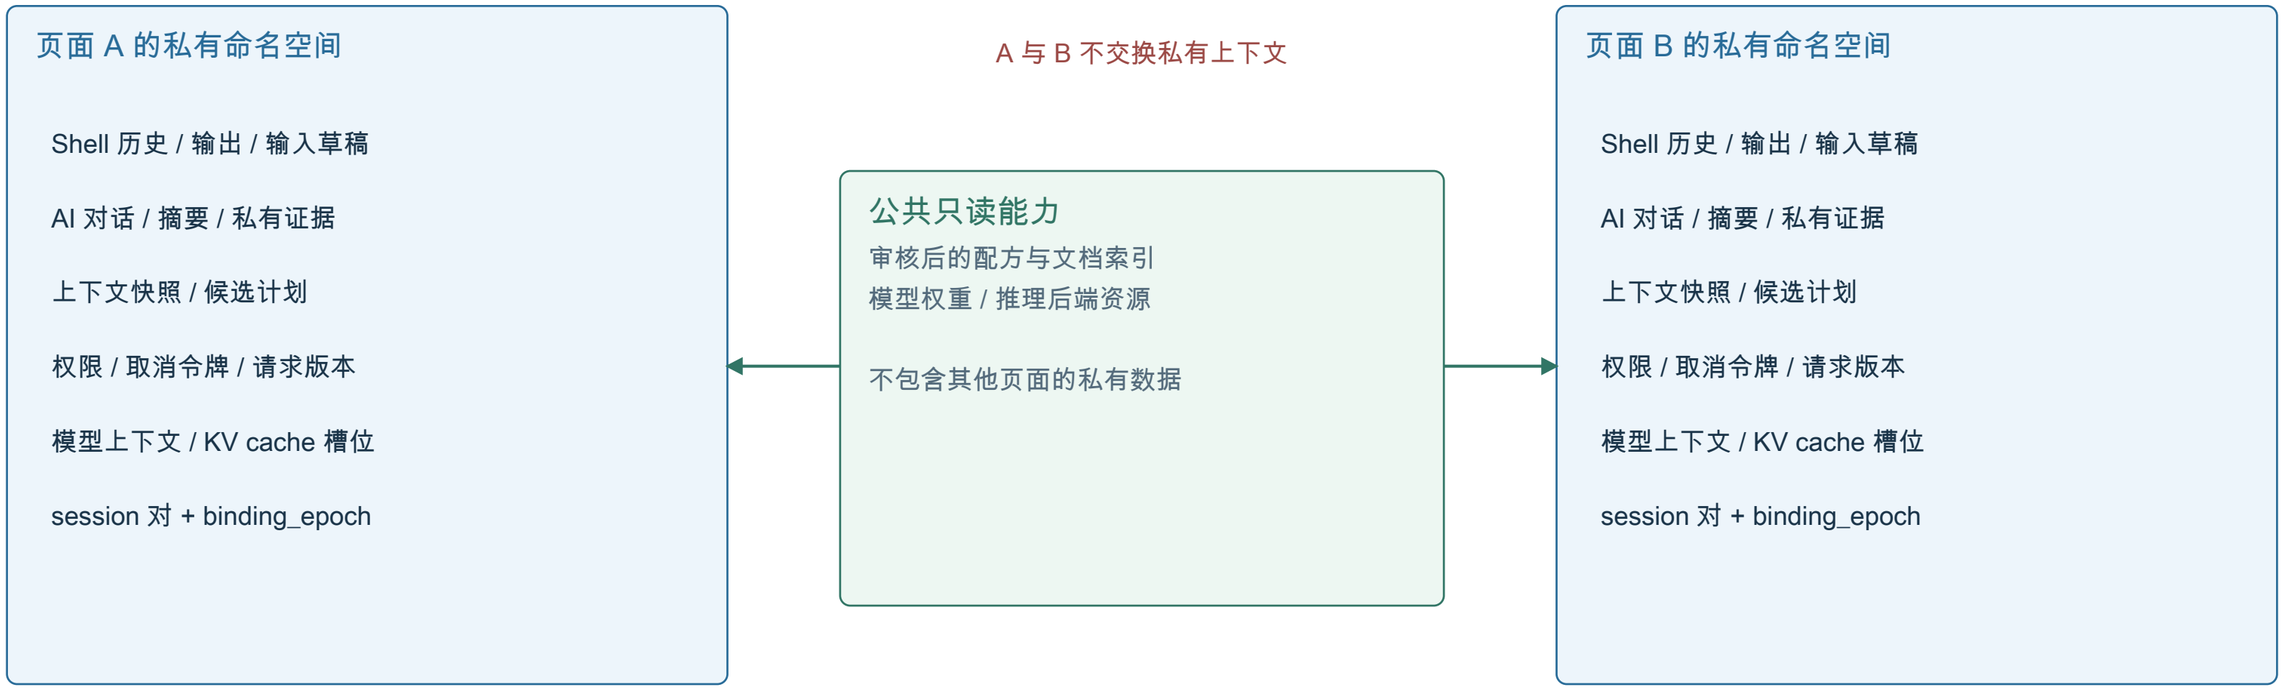
03 用户 Enter 后才产生 command.started；原始输出留在主 Shell，额外验证报告只显示在侧栏。

06 / 数据隔离与共享资源边界

页面之间不通信是默认会话策略；公共只读知识和底层算力复用需要与私有状态隔离。

图 06 隔离边界：私有会话不共享，公共只读能力可复用

默认按页面分区；共享 AIWorker 或模型权重，不代表共享聊天历史、授权与执行目标。



隔离承诺：应用层不串页、不串历史、不串授权。共享服务仍属于可信基础设施。

不是完整 OS 沙箱：两个 Shell 若能访问同一目录，仍可通过真实文件变化互相影响。

01 每页隔离历史、上下文、草稿、计划、取消令牌与授权；所有返回结果固定绑定原请求。

02 共享 AIWorker 中采用逻辑隔离，不等于独立 OS 地址空间；UI、路由和推理后端属于可信边界。

03 如需要连文件访问都隔离，应另外设计系统沙箱与独立工作区；不能把 Session 隔离当成安全沙箱。

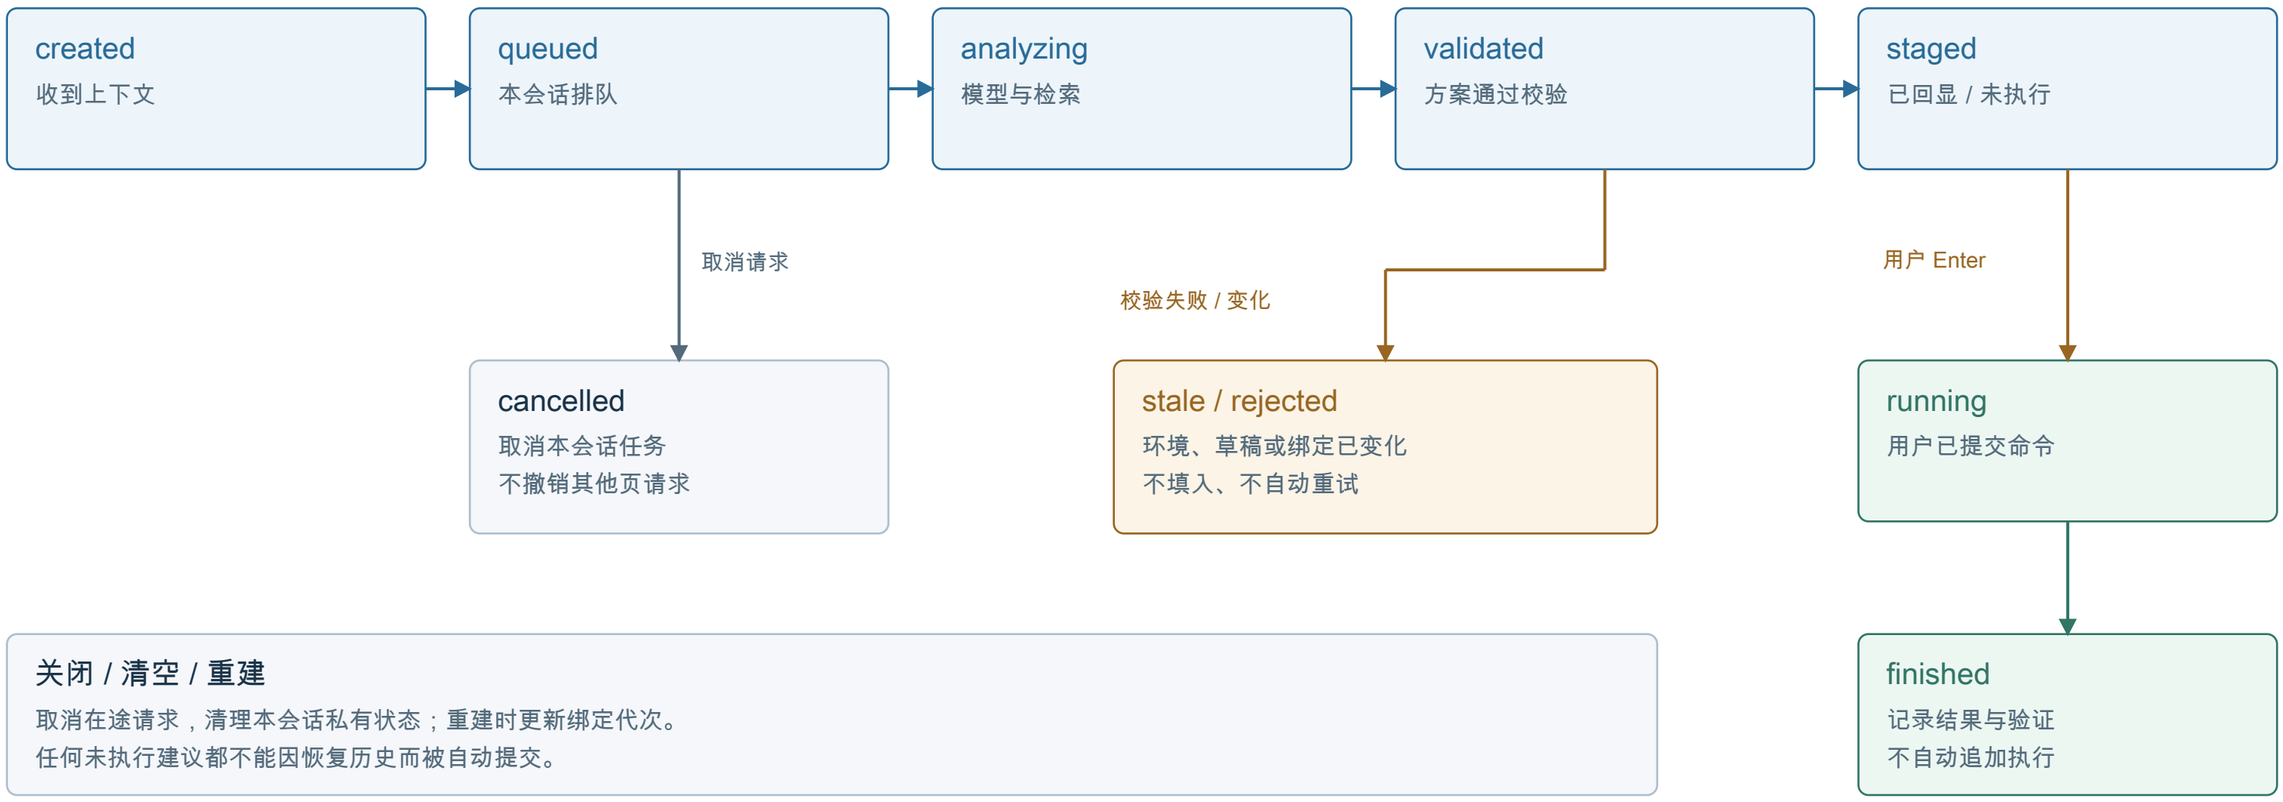
07 / 生命周期、取消与故障恢复

创建、清空、取消和销毁由 AISession 向下管理；恢复历史不恢复隐含执行权限。

图 07 建议生命周期：取消、过期与恢复都不隐含执行

状态归属本会话；重建后换 binding_epoch，旧结果和旧批准不得自动重放。

已回显的建议也可由用户清除；取消、过期不是执行成功或事务回滚。



01 取消只作用于所属会话的任务、模型请求和未执行建议；不触发其他页的取消或输入变化。

02 上下文、提示符、输入或绑定变化都可使方案过期；晚到回复最多保留历史，不能强行回显。

03 重启 PageHost 或 AIWorker 后更新绑定代次；同一 proposal 的重试必须幂等，不重放用户 Enter。

08 / 最小通信契约与回显检查

逻辑协议在两种部署中保持一致；同进程可用类型化队列，跨进程使用受保护 IPC。

消息	方向	语义
shell.context.snapshot	Shell → AI	本页最小事实快照；带上下文、提示符及输入版本
shell.context.changed	Shell → AI	目录、环境或目标发生变化，使相关旧建议失效
shell.command.finished	Shell → AI	关联命令、退出状态、限量输出与截断说明
ai.context.request	AI → Shell	申请额外只读信息；仍需本页授权与范围检查
ai.command.propose	AI → Shell	完整候选命令、配方版本、计划摘要与预期状态
shell.command.stage_result	Shell → AI	已填入或拒绝原因；不表示已经执行
shell.command.started	Shell → AI	用户提交后真实执行开始，不接受模型伪造
request.cancel / session.close	双向 / Supervisor	撤销本页在途工作或关闭绑定，阻止晚到消息

消息必须绑定的身份

page_id · shell_session_id · ai_session_id · binding_epoch · task_id · request_id · message_id

回显检查

绑定与实际通道一致 → 请求未取消 → 计划有效 → 上下文未过期 → 前台是空闲 Shell → 输入版本一致 → 命令完整安全转义。

拒绝路径

INPUT_CHANGED / SHELL_BUSY / STALE_CONTEXT / BINDING_MISMATCH / INVALID_PROPOSAL；只在侧栏解释，不覆盖当前草稿。

09 / 验收清单、待决策事项与演进记录

报告是已确认约束与候选实现的总结，不是 Harmony 平台兼容性认证，也不新增跨页授权。

第一版必须验证

01 A/B 请求并发和乱序响应，不串页、不改绑。

02 用户编辑或开始下一条命令后，旧建议不可覆盖。

03 编辑器、REPL、续行或输入法提交时不注入。

04 回显不执行；AI 区的 Enter 只提交问题。

05 重复 proposal、回执丢失不产生重复回显。

06 取消或关闭 A，不影响 B 的历史、队列与输入。

07 共享 AI 进程故障不结束外部普通 Shell。

08 重建绑定后拒绝旧消息，不重放批准或 Enter。

09 模型缓存与云端对话不泄漏另一页上下文。

10 AI / verify 消息不污染主窗口原始输出。

尚待确定，不在本报告中定案

部署默认值

模式 A 或共享 AIWorker；是否需要独立 AI 安全域。

线程与 IPC

具体运行时、线程数、队列预算、背压和连接实现。

模型服务后端

本地或云端、权重复用、私有缓存策略与上传授权。

平台适配

设备 / 系统 / Shell、PTY 与行编辑集成、系统权限。

工作组模式

多个 Shell 共用一个逻辑对话仍属备选，默认不开启。

关键演进

D-012：一页一对 Session 与统一协议；D-013：补充共享 AI 进程；D-014：调度器和模型服务下沉至 AISession 内部。

已替代：将全局业务调度器、模型网关与 AISession 平级。历史内容保留在讨论文档，不作为当前架构。

依据：SESSION_PROTOCOL.md v0.3、TECHNICAL_ARCHITECTURE.md v0.4、PROJECT_DISCUSSIONS.md（D-012 至 D-014）。